Постановка задачи

Объект исследования: рынок жилой недвижимости Санкт-Петербурга.
Предмет исследования: зависимость стоимости квартиры от ее характеристик.
Цель: построить регрессионную модель зависимости стоимости квартиры (ЦФ) от набора факторов (X) и оценить вклад каждого фактора.
Целевая функция: цена за квадратный метр (Y).

Факторы (X):

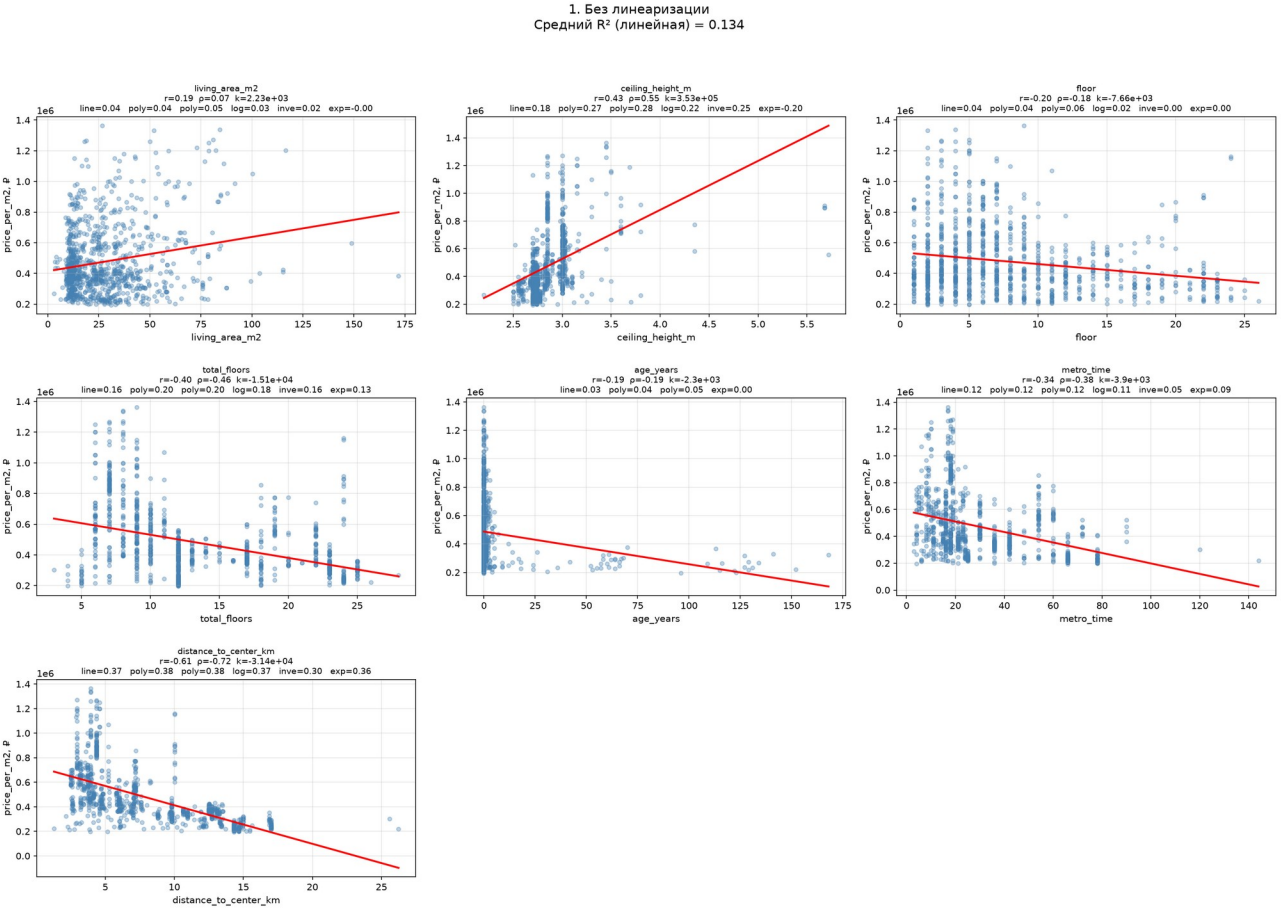
Фактор	**Обозначение**	**Единица измерения**	**Тип**
Общая площадь	X_1	$М^2$	Числовой
Этаж	X_2	Этаж	Числовой
Метро	X_3	Мин	Числовой
Год постройки	X_4	Год	Числовой
Жилая площадь	X_5	$М^2$	Числовой
Площадь кухни	X_6	$М^2$	Числовой
Высота потолков	X_7	$М^2$	Числовой

Источник данных: объявления о продаже квартир на Циан в Санкт-Петербурге
Объем выборки: 60 уникальный квартир для обучения модели и 20 квартир для проверки.

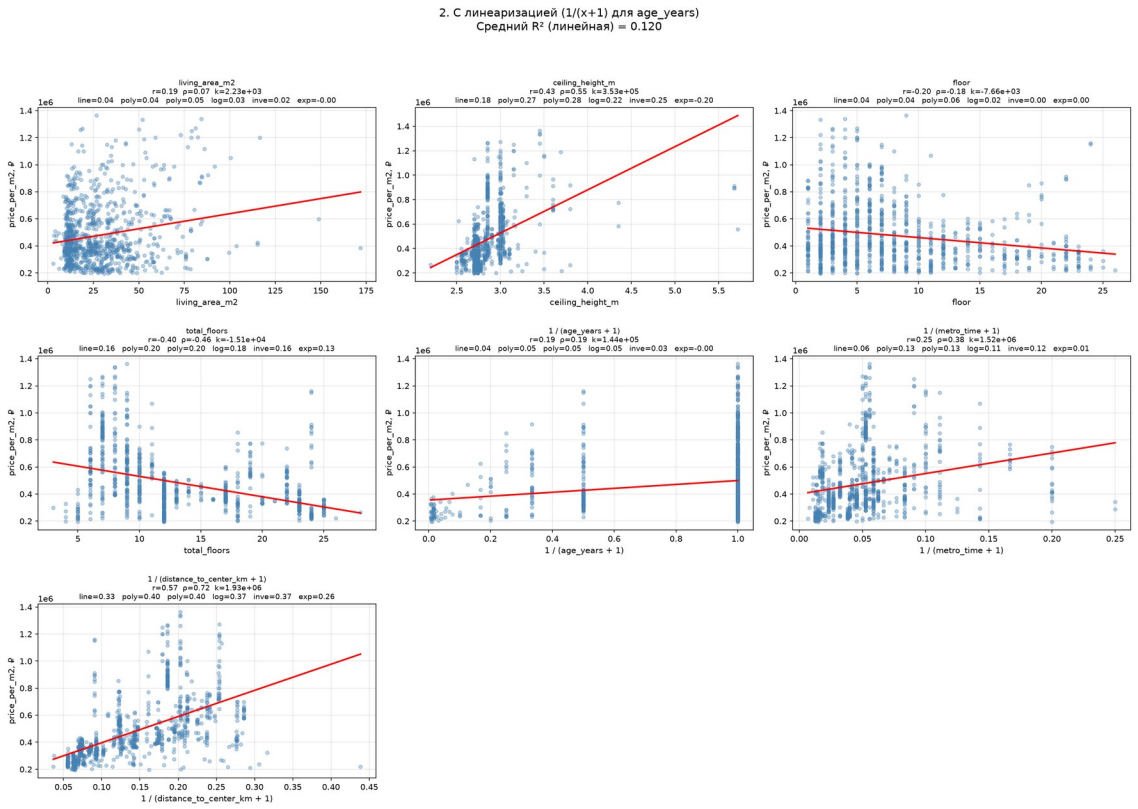
Обоснование вида модели

Для обоснования вида модели были построенны диаграммы рассеяния зависимости цены квартиры за кв м от каждого из факторов: Общая площадь, этаж, метро, год постройки, жилая площадь, площадь кухни, высота потолков.

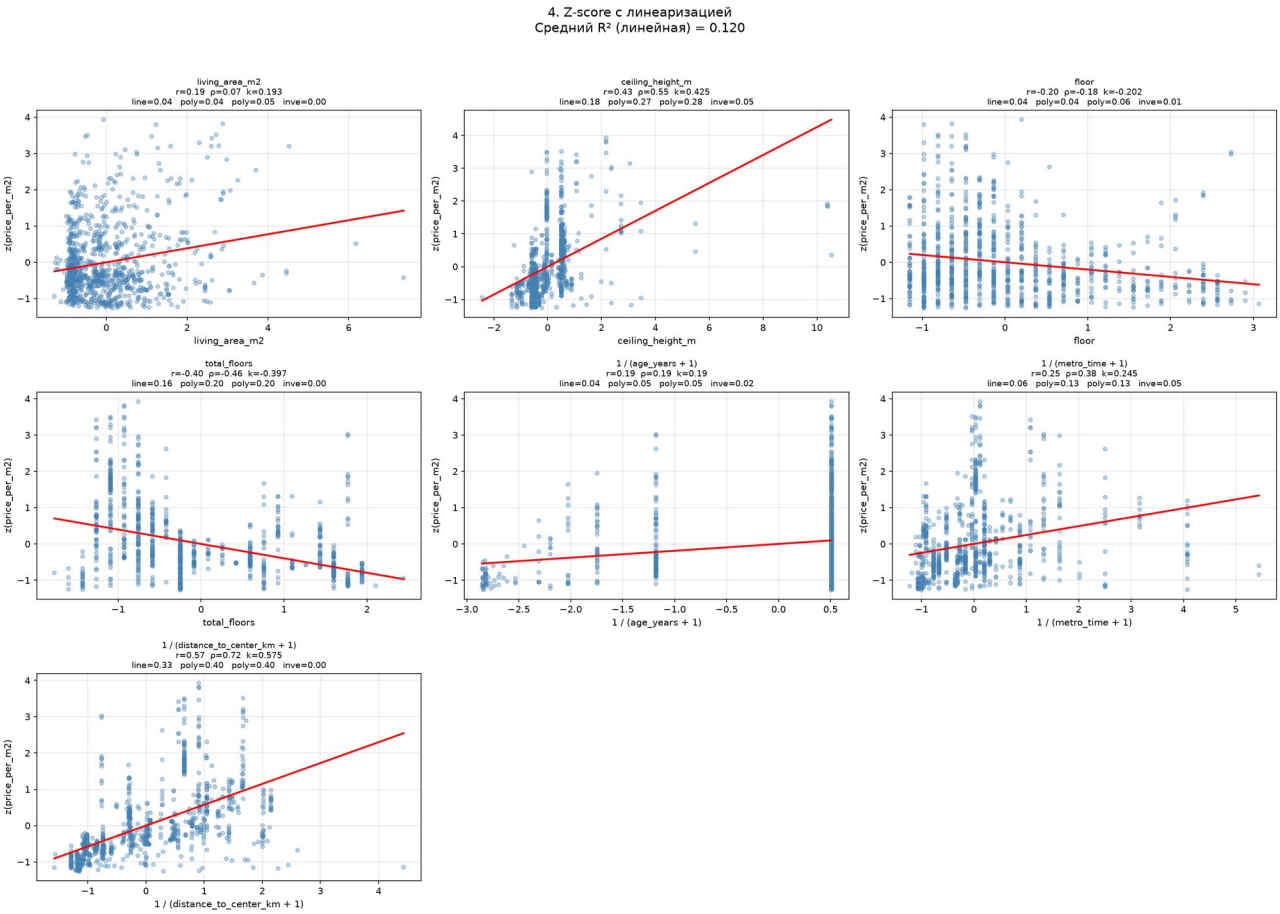
На каждый график добавлена аппроксимирующая прямая, рассчитанная методом наименьших квадратов.



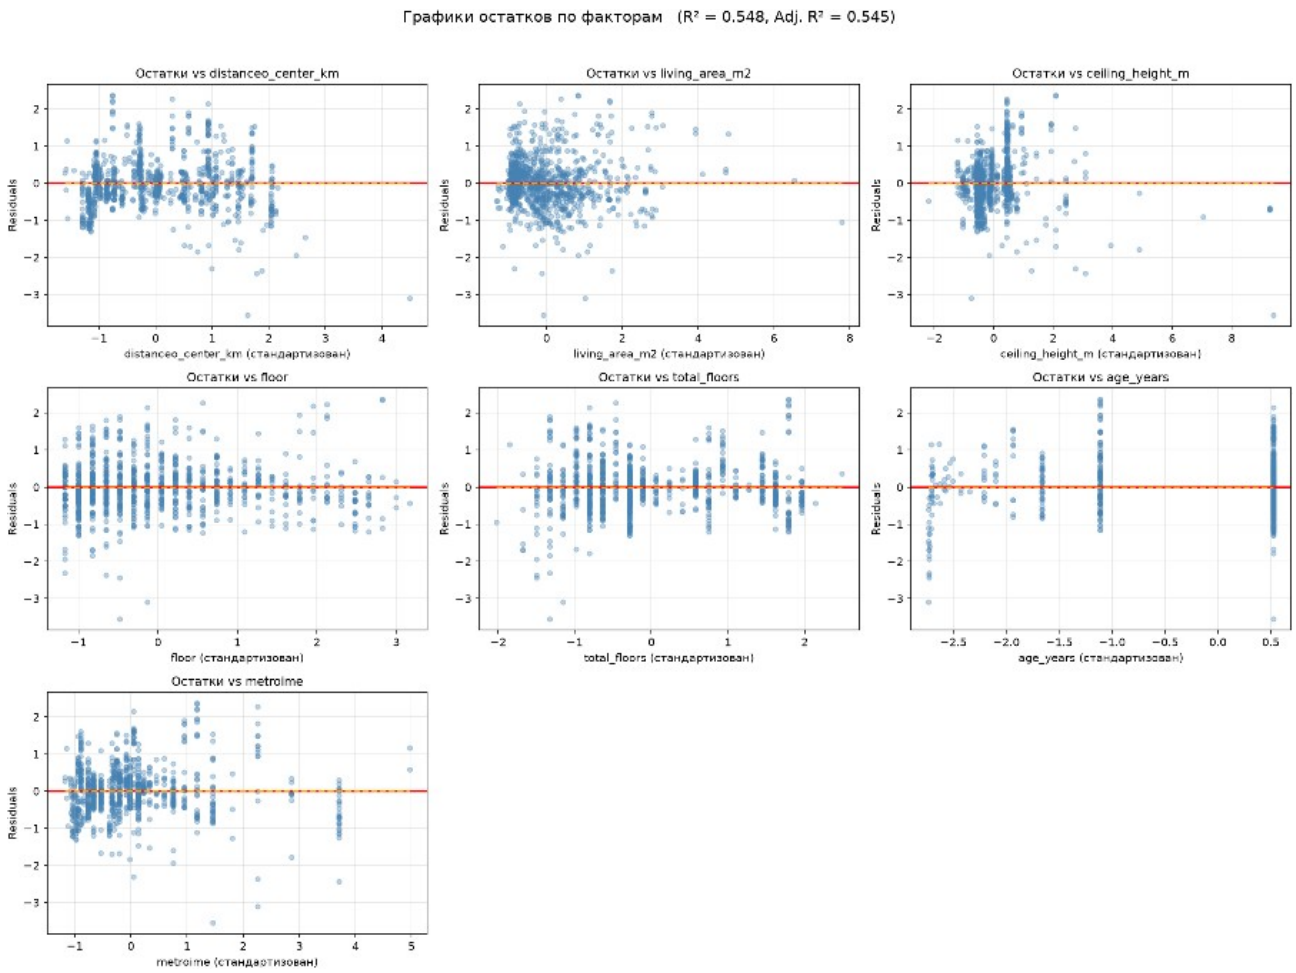
Наборы точек без линеаризации и нормирования



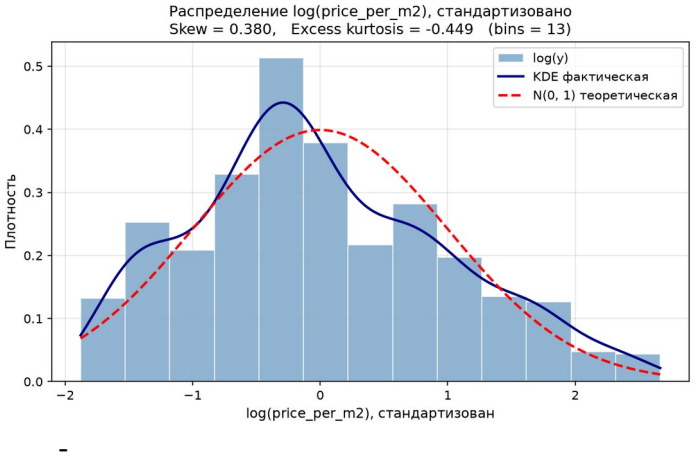
Наборы точек с линеаризацией

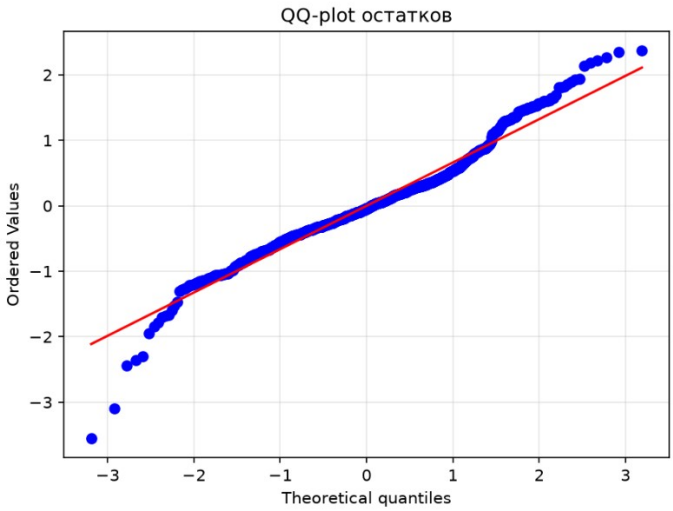


Наборы точек с линеаризацией и нормированием



Графики остатков по факторам





ЦФ, факторы, количество уровней каждого фактора, тип дублирования и максимальное число параллельных данных

ЦФ — цена за квадратный метр квартиры в СПБ.
Факторы (X):

Фактор	Что это	Обозначение	Единица измерения	Тип
distance_to_center_km	**Расстояние от дома до Дворцовой площади**	X_1	Км	Числовой
living_area_m2	**Жилая площадь**	X_2	$М^2$	Числовой
ceiling_height_m	**Высота потолков**	X_3	М	Числовой
floor	**Этаж**	X_4		Числовой
total_floors	**Количество этажей в доме**	X_5		Числовой
age_years	**Возраст постройки**	X_6	Год	Числовой
metro_time	**Время до метро пешком**	X_7	Мин	Числовой

Уровень каждого фактора:
Уровень фактора — конкретное значение, которое фактор принимает в наблюдении

Если фактор **непрерывный** (в случае с **distance_to_center_km**), число уровней = число уникальных значений в данных.

Если фактор **дискретный** (например **floor**), число уровней = число различных этажей.

Если фактор категориальный (например тип дома), число уровней = число категорий.
Это все делается методом nunique()

```
print("Уровни факторов (число уникальных значений в CSV):")
for col in FACTORS:
    if col in data.columns:
        n = data[col].nunique()
        print(f"  {col:25s} {n} уровней")
```

```
Уровни факторов (число уникальных значений в CSV):
  distance_to_center_km     240 уровней
  living_area_m2            724 уровней
  ceiling_height_m          69 уровней
  floor                     26 уровней
  total_floors              26 уровней
  age_years                 53 уровней
  metro_time                39 уровней
```

Параллельные данные — это несколько измерений y при одинаковых значениях всех факторов x_1,x_2...x_7.

В моем случае — 1. Так как каждое объявление на Cian — уникально, то полностью одинаковых по всем показателям квартир — нет.

Поиск идет командой:

```
groups = data.groupby(FACTORS).size()

max_parallel = groups.max()
```

Формальная постановка задачи

Пусть **n** — число наблюдений (в моем случае — квартир), **k** — число факторов.
Y — цена за квадратный метр квартиры.
Для модели используется логарифмическое преобразование
***y** = ln(price_per_m2)*, где price_per_m2 — цена за м^2 из данных Cian.

Модель

Предполагается, что зависимость ЦФ от факторов линейна по коэффициентам и имеет вид:

$$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \beta_3 \cdot x_3 + \beta_4 \cdot x_4 + \beta_5 \cdot x_5 + \beta_6 \cdot x_6 + \beta_7 \cdot x_7 + \varepsilon$$

где

β_0 — свободный член (intercept, константа);
$\beta_1, \ \ldots, \ \beta_7$ — неизвестные коэффициенты регрессии;
ε — случайная ошибка,

Для фактора X_6(возраст дома), X_7(время до метро пешком) и X_1(расстояние до центра в км) применено преобразование:

$x_6' = 1 / (\mathbf{age_years} + 1)$
$x_7' = 1 / (\mathbf{metro_time} + 1)$
$x_1' = 1 / (\mathbf{distance_to_center_km} + 1)$

Это линеаризует гиперболическую зависимость цены от возраста дома, времени до ближайшего метро пешком и расстояния от дома до центра города.
В модели используется x_1', x_6', x_7'.

Задача оценивания

Требуется найти оценки $\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_7$ неизвестных коэффициентов $\beta_0, \beta_1, \ldots, \beta_7$ **методом наименьших квадратов (МНК)**. То есть минимизировать сумму квадратов остатков: $S(\beta) = \Sigma_{i=1}^{n} (y_i - \beta_0 - \beta_1 \cdot x_{i1} - \ldots - \beta_7 \cdot x_{i7})^2 \ \rightarrow \ \min$

Матричная форма: $y = X \cdot \beta + \varepsilon$
Решение МНК: $\hat{\beta} = (X^T \cdot X)^{-1} \cdot X^T \cdot y$

Это решение системы нормальных уравнений СНУ: $(X^T \cdot X) \cdot \beta = X^T \cdot y$

Матрица уровней, матрица результатов

Матрица уровней представлена в таблице X_matrix.csv. В ней записаны все нормализованные значения параметров **X**

row_id	distanceo_center_km	living_area_m2	ceiling_height_m	floor	total_floors	age_years	metroime
1	2.0549869779701813	-0.8839948775226639	-1.0362420646775 87	-1.1508755224700634	1.597431693666687	0.50742720780708	-0.21709648453154798
2	-0.17458680312386 94	-0.9141971126638654	0.5478104339232343	0.5354840122583685	0.9232640056134376	0.50742720780708	1.3108323346570416
3	-0.9162462223755463	0.2273449952132354	0.5101906683743807	-0.13905980163298506	-0.7621552145196864	0.50742720780708	-0.5736132090888856
4	-0.8639682353222087	-0.7196742422632335	0.5838302594720897	-0.8136036155243306	-0.2565294484797492	0.50742720780708	1.3108323346570416

Матрица результатов представлена в таблице y_matrix.csv. В ней записаны результаты **Y** для каждой квартиры.

	row_id	log_price
1	1	-1.2635695554728519
2	2	0.622887886760598
3	3	2.2706903507257787
4	4	0.41706592576275964
5	5	1.7131660659551824

СНУ

СНУ — система нормальных уравнений. Это система линейных уравнений относительно неизвестных коэффициентов $\beta_0, \beta_1, \ldots, \beta_k$, решение которой даёт МНК-оценки

Появление: минимизируем сумму квадратов остатков $S(\beta) = \Sigma_i (y_i - \beta_0 - \beta_1 \cdot x_{i1} - \ldots - \beta_k \cdot x_{ik})^2$
Чтобы найти минимум, берем **частные производные** по каждому β_j и приравниваем к нулю:
$\partial S/\partial \beta_0 = 0$
$\partial S/\partial \beta_1 = 0$
…
$\partial S/\partial \beta_k = 0$.
Каждое такое уравнение — линейное относительно β. Вместе получается система из k + 1 уравнений с k + 1 неизвестными. Это и есть **СНУ**.

```
ШАГ 1. Обозначения
n = 975 — число наблюдений (квартир)
k = 7 — число факторов

 Факторы:
 x1 = distanceo_center_km
 x2 = living_area_m2
 x3 = ceiling_height_m
 x4 = floor
 x5 = total_floors
 x6 = age_years
 x7 = metroime

 Целевая функция:
 y = log1p(price_per_m2)

 Применённые преобразования к факторам:
 distance_to_center_km -> 1 / (distance_to_center_km + 1)
 age_years             -> 1 / (age_years + 1)
 metro_time            -> 1 / (metro_time + 1)

ШАГ 2. Модель

 Линейная зависимость:

 y = β0 + β1·x1 + β2·x2 + ... + βk·xk + ε

 Для k = 7 факторов:
 y = β0 + β1·x1 + β2·x2 + β3·x3 + β4·x4 + β5·x5 + β6·x6 + β7·x7 + ε

ШАГ 3. Функция потерь (сумма квадратов остатков)

 Остаток для i-го наблюдения:
```

e_i(β0, β1, ..., βk) = y_i − β0 − β1·x_i1 − ... − βk·x_ik

Сумма квадратов остатков:

S(β0, β1, ..., βk) = Σ_(i=1..1171) [e_i]²

Раскрыто:

S(β) = Σ_(i=1..1171) (y_i − β0 − β1·x_i1 − β2·x_i2 − ... − βk·x_ik)²

Это функция (k+1) переменных: β0, β1, ..., βk.

ШАГ 4. Частные производные и приравнивание к нулю

Минимум S достигается там, где все частные производные
по β0, β1, ..., βk равны нулю:

∂S/∂β0 = 0
∂S/∂β1 = 0
∂S/∂β2 = 0
∂S/∂β3 = 0
∂S/∂β4 = 0
∂S/∂β5 = 0
∂S/∂β6 = 0
∂S/∂β7 = 0

Это даёт ровно (k+1) уравнений.

ШАГ 5. Система нормальных уравнений — символьно

Раскрывая производные и перенося слагаемые, получаем:

(1) Уравнение для β0:
n·β0 + β1·Σx1 + β2·Σx2 + β3·Σx3 + β4·Σx4 + β5·Σx5 + β6·Σx6 + β7·Σx7 = Σy

(2) Уравнение для β1:
β0·Σx1 + β1·Σ(x1·x1) + β2·Σ(x2·x1) + β3·Σ(x3·x1) + β4·Σ(x4·x1) +
β5·Σ(x5·x1) + β6·Σ(x6·x1) + β7·Σ(x7·x1) = Σ(x1·y)

(3) Уравнение для β2:
β0·Σx2 + β1·Σ(x1·x2) + β2·Σ(x2·x2) + β3·Σ(x3·x2) + β4·Σ(x4·x2) +
β5·Σ(x5·x2) + β6·Σ(x6·x2) + β7·Σ(x7·x2) = Σ(x2·y)

(4) Уравнение для β3:
β0·Σx3 + β1·Σ(x1·x3) + β2·Σ(x2·x3) + β3·Σ(x3·x3) + β4·Σ(x4·x3) +
β5·Σ(x5·x3) + β6·Σ(x6·x3) + β7·Σ(x7·x3) = Σ(x3·y)

(5) Уравнение для β4:
β0·Σx4 + β1·Σ(x1·x4) + β2·Σ(x2·x4) + β3·Σ(x3·x4) + β4·Σ(x4·x4) + β5·Σ(x5·x4) + β6·Σ(x6·x4) + β7·Σ(x7·x4) = Σ(x4·y)

(6) Уравнение для β5:
β0·Σx5 + β1·Σ(x1·x5) + β2·Σ(x2·x5) + β3·Σ(x3·x5) + β4·Σ(x4·x5) + β5·Σ(x5·x5) + β6·Σ(x6·x5) + β7·Σ(x7·x5) = Σ(x5·y)

(7) Уравнение для β6:
β0·Σx6 + β1·Σ(x1·x6) + β2·Σ(x2·x6) + β3·Σ(x3·x6) + β4·Σ(x4·x6) + β5·Σ(x5·x6) + β6·Σ(x6·x6) + β7·Σ(x7·x6) = Σ(x6·y)

(8) Уравнение для β7:
β0·Σx7 + β1·Σ(x1·x7) + β2·Σ(x2·x7) + β3·Σ(x3·x7) + β4·Σ(x4·x7) + β5·Σ(x5·x7) + β6·Σ(x6·x7) + β7·Σ(x7·x7) = Σ(x7·y)

ШАГ 6. То же в матричной форме

Введём матрицу уровней X размера n × (k+1):
первый столбец — единицы (для β0),
остальные k столбцов — значения факторов.

$$\begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix}$$

Вектор результатов y размера n × 1:
$y = (y_1, y_2, \dots, y_n)^T$

Вектор коэффициентов β размера (k+1) × 1:
$\beta = (\beta 0, \beta 1, \dots, \beta k)^T$

Тогда СНУ записывается как:

$$(X^T \cdot X) \cdot \beta = X^T \cdot y$$

Решение:

$$\beta = (X^T \cdot X)^{-1} \cdot X^T \cdot y$$

ШАГ 7. Матрица X^TX — численно

	const	distanceo_center_km	living_area_m2	ceiling_height_m	floor	total_floors	age_years_transformed	metroime
const	975.0000	-0.0000	0.0000	-0.0000	0.0000	0.0000	0.0000	0.0000
distanceo_center_km	-0.0000	975.0000	-172.1507	-292.7328	395.5548	562.9847	32.2603	431.5392
living_area_m2	0.0000	-172.1507	975.0000	157.0423	-17.0707	-95.3588	-247.4088	-173.9906
ceiling_height_m	-0.0000	-292.7328	157.0423	975.0000	12.7570	-86.9236	-79.8621	-156.9577
floor	0.0000	395.5548	-17.0707	12.7570	975.0000	652.5536	-55.8181	55.6888
total_floors	0.0000	562.9847	-95.3588	-86.9236	652.5536	975.0000	33.9769	232.2690
age_years_transformed	0.0000	32.2603	-247.4088	-79.8621	-55.8181	33.9769	975.0000	190.6075
metroime	0.0000	431.5392	-173.9906	-156.9577	55.6888	232.2690	190.6075	975.0000

Что означают элементы:

- $(X^TX)[0,0] = n = 975$ — число наблюдений
- $(X^TX)[0,j] = \Sigma x_j$ — сумма j-го фактора
- $(X^TX)[i,j] = \Sigma(x_i \cdot x_j)$ — сумма произведений
- $(X^TX)[j,j] = \Sigma x_j^2$ — сумма квадратов j-го фактора

ШАГ 8. Вектор X^Ty — численно

Размер: 8 × 1

	X^Ty
const	0.0000
distanceo_center_km	-674.2821
living_area_m2	142.8777
ceiling_height_m	412.7685
floor	-211.1207
total_floors	-384.9087
age_years_transformed	209.4626
metroime	-373.8496

Что означают элементы:

- $(X^Ty)[0] = \Sigma y$ — сумма целевой переменной
- $(X^Ty)[j] = \Sigma(x_j \cdot y)$ — сумма произведений

ШАГ 9. Система в матричной форме — с числами

$$(X^T \cdot X) \cdot \beta = X^T \cdot y$$

Решение (β):

коэффициент	значение
const	0.000000
distanceo_center_km	-0.539182
living_area_m2	0.056468
ceiling_height_m	0.245705
floor	0.086527
total_floors	-0.091744
age_years_transformed	0.302122
metroime	-0.137310

Обоснование коэффициентов

Видим, что самые сильные коэффициенты — это расстояние до цетра, высота потолков, и возраст дома. Также есть побочные параметры, которые слабее определяют стоимость квартиры: жилая площадь, этаж, количество этажей в доме, время от дома до метро пешком

```
# ============================================================
# МНК вручную
# ============================================================
def manual_ols(X: pd.DataFrame, y: pd.Series):
    Xc = np.column_stack([np.ones(len(X)), X.values])
    yv = y.values
    XtX = Xc.T @ Xc
    Xty = Xc.T @ yv
    beta = np.linalg.solve(XtX, Xty)
    return beta, XtX, Xty, Xc
```

Автоматический рассчет параметров модели

Далее применяем автоматический рассчет коэффициентов с помощью statsmodels

```python
# ============================================================
# АВТОМАТИЧЕСКИЙ РАСЧЁТ (statsmodels)
# ============================================================
def fit_auto_ols(X: pd.DataFrame, y: pd.Series):  1 usage
    Xc = sm.add_constant(X, prepend=True)
    model = sm.OLS(y, Xc).fit()
    return model
```

```
================================================
ИТОГОВЫЕ КОЭФФИЦИЕНТЫ (β)
================================================
  const                          = +0.000000
  distanceo_center_km            = -0.539182
  living_area_m2                 = +0.056468
  ceiling_height_m               = +0.245705
  floor                          = +0.086527
  total_floors                   = -0.091744
  age_years                      = +0.302122
  metroime                       = -0.137310

R²       = 0.620216
Adj. R²  = 0.617466
F        = 225.5974
Prob(F)  = 2.4113e-198
```

Сравнение

через np.linalg.solve + формулы

```
Решение (β):

                коэффициент  значение
                      const  0.000000
     distanceo_center_km -0.539182
           living_area_m2  0.056468
        ceiling_height_m  0.245705
                   floor  0.086527
             total_floors -0.091744
age_years_transformed  0.302122
                 metroime -0.137310
```

через statsmodels

```
==========================================
ИТОГОВЫЕ КОЭФФИЦИЕНТЫ (β)
==========================================
  const                    = +0.000000
  distanceo_center_km      = -0.539182
  living_area_m2           = +0.056468
  ceiling_height_m         = +0.245705
  floor                    = +0.086527
  total_floors             = -0.091744
  age_years                = +0.302122
  metroime                 = -0.137310
```

Можно заметить, что коэффициенты, полученные через statmodels точно такие же, как и коэффициенты, полученные через linalg.solve

Модель с рассчитанными параметрами

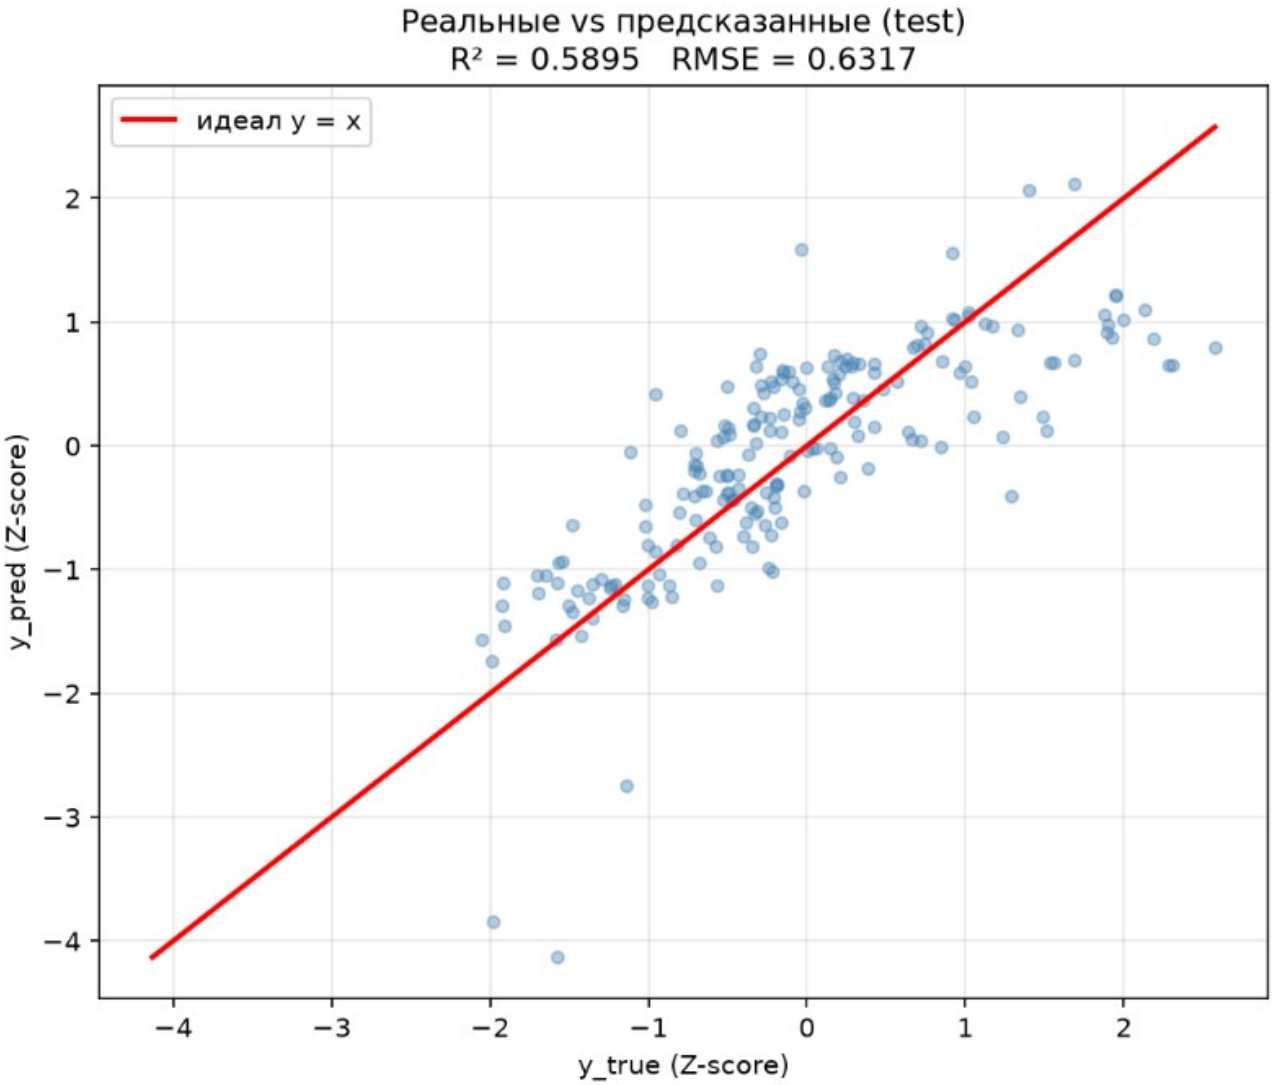
```
МОДЕЛЬ С РАССЧИТАННЫМИ ПАРАМЕТРАМИ
================================================================================

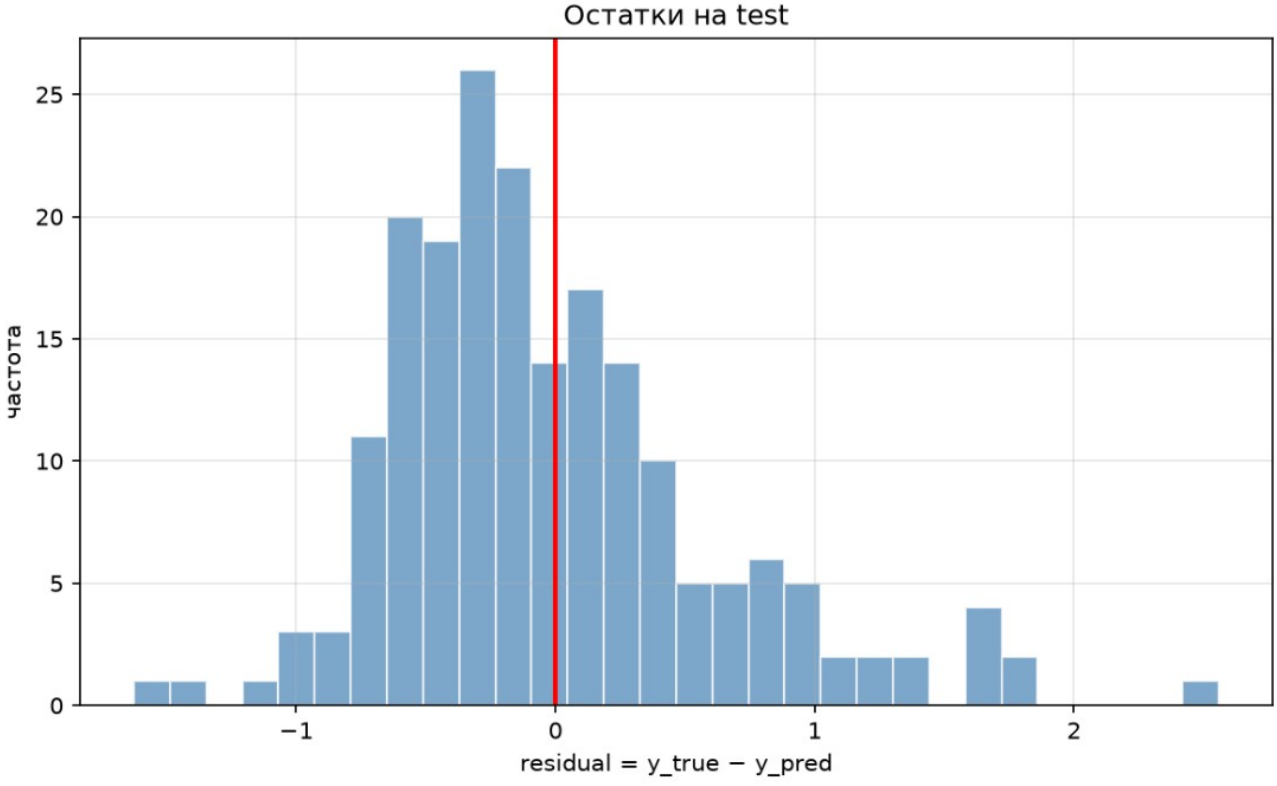
Уравнение регрессии в общем виде:
    y = β0 + β1·x1 + β2·x2 + ... + βk·xk

Конкретные значения:
    y = 0.0000
        − 0.5392 · distanceo_center_km
        + 0.0565 · living_area_m2
        + 0.2457 · ceiling_height_m
        + 0.0865 · floor
        − 0.0917 · total_floors
        + 0.3021 · age_years
        − 0.1373 · metroime

Где y = log1p(price_per_m2), а факторы:
    x1 = distanceo_center_km
    x2 = living_area_m2
    x3 = ceiling_height_m
    x4 = floor
    x5 = total_floors
    x6 = age_years
    x7 = metroime

Метрики качества:
    R²          = 0.6202
    Adj. R²     = 0.6175
    F-statistic = 225.5974
    Prob (F)    = 2.4113e-198
    N (строк)   = 975
```


Реальные vs предсказанные (test)
R² = 0.5895 RMSE = 0.6317
идеал y = x
y_pred (Z-score)
y_true (Z-score)


Остатки на test
частота
residual = y_true − y_pred